

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA

DCT1401 - INTELIGÊNCIA ARTIFICIAL
Bacharelado em Sistemas da Informação (BSI)

Período Letivo: 2026.2
Professor: Thommas K. S. Flores

Análise Exploratória e Preparação de Dados para
Modelos de Aprendizado de Máquina

Atividade Prática Avaliativa

Contexto e Cenário

Você foi contratado como **Cientista de Dados** por uma empresa de consultoria analítica. A empresa recebeu um conjunto de dados de um cliente e precisa de uma análise completa para orientar a construção de modelos de Machine Learning. O dataset está disponível em uma planilha eletrônica, conforme indicado na coluna "**link_do_dataset**" da planilha de matrícula da turma.

Importante: Cada aluno(a) deve utilizar o dataset associado à sua matrícula na planilha oficial da disciplina. A utilização de um dataset diferente resultará em penalização na nota.

O cliente deseja resolver **dois tipos de problemas** distintos, ambos a partir do mesmo conjunto de dados bruto:

- 1. Problema de Regressão:** Prever uma variável numérica contínua (a ser identificada por você, justificando sua escolha).
- 2. Problema de Classificação:** Prever uma variável categórica (a ser identificada por você, justificando sua escolha, ou transformada a partir de uma variável contínua, se necessário).

Objetivos da Atividade

O objetivo desta atividade é avaliar sua capacidade de conduzir uma análise exploratória de dados completa, realizar a limpeza e o pré-processamento necessários e interpretar os dados para propor soluções adequadas para os dois paradigmas de aprendizado: **supervisionado (regressão)** e **supervisionado (classificação)**.

Ao final, você deverá entregar um relatório técnico que documente todo o processo, desde a compreensão inicial dos dados até as percepções finais que guiariam a modelagem.

Tarefas e Diretrizes Detalhadas

0.1 1. Análise Exploratória de Dados (EDA)

- **Carregamento e Inspeção Inicial:**

- Carregue o dataset utilizando uma biblioteca apropriada (ex.: `pandas` em Python ou outra de sua preferência).
- Exiba as primeiras e últimas linhas do dataset para uma visão geral.
- Verifique as dimensões do dataset (número de linhas e colunas).
- Identifique os tipos de dados de cada coluna (numéricos, categóricos, texto, data, etc.).

- **Estatísticas Descritivas:**

- Gere um resumo estatístico das variáveis numéricas (média, mediana, desvio padrão, quartis, mínimo e máximo).
- Para variáveis categóricas, apresente as frequências das categorias.

- **Identificação de Valores Ausentes:**

- Calcule a quantidade e a porcentagem de valores ausentes por coluna.
- Visualize a distribuição dos valores ausentes (ex.: mapa de calor, gráfico de barras).
- Discuta o impacto potencial desses valores ausentes na análise e na modelagem.

- **Deteção de Outliers:**

- Utilize métodos estatísticos (ex.: IQR – Intervalo Interquartil) e visuais (ex.: boxplots) para identificar outliers nas variáveis numéricas.
- Comente sobre a presença e a possível origem desses outliers.

- **Análise de Correlação:**

- Calcule a matriz de correlação para variáveis numéricas.
- Visualize a matriz de correlação (ex.: heatmap).
- Identifique pares de variáveis com alta correlação (positiva ou negativa) e discuta suas implicações (ex.: multicolinearidade).

- **Visualização de Dados:**

- Gere pelo menos **3 visualizações diferentes** que ajudem a entender a distribuição dos dados e a relação entre variáveis (ex.: histogramas, gráficos de densidade, scatter plots, pair plots).
- Para variáveis categóricas, utilize gráficos como contagem de barras ou pizza.

0.2 2. Limpeza e Pré-processamento dos Dados

Após a análise exploratória, realize as seguintes etapas de tratamento:

- **Tratamento de Valores Ausentes:**

- Justifique a estratégia escolhida para cada coluna com valores ausentes (ex.: remoção da linha, imputação pela média/mediana/modas, imputação por valor constante, ou uso de modelos de imputação mais complexos).
- Aplique a estratégia escolhida e documente as alterações feitas no dataset.

- **Tratamento de Outliers:**

- Decida se irá remover, transformar (ex.: log) ou manter os outliers. Justifique sua decisão para cada caso relevante, considerando o impacto nos modelos futuros.

- **Codificação de Variáveis Categóricas:**

- Identifique as variáveis categóricas e aplique técnicas de codificação apropriadas (ex.: One-Hot Encoding, Label Encoding). Explique a diferença entre essas técnicas e quando cada uma é mais adequada.

- **Normalização/Padronização (se necessário):**

- Avalie a necessidade de normalizar ou padronizar as variáveis numéricas, considerando os algoritmos que serão usados (ex.: modelos baseados em distância como KNN ou SVM se beneficiam disso).
- Aplique a técnica (ex.: Min-Max Scaling, Z-score) e justifique.

0.3 3. Percepções para Regressão e Classificação

Nesta etapa, você deve conectar a análise e o pré-processamento com os dois problemas-alvo.

- **Identificação da Variável Alvo (Target) para Regressão:**

- Analise as colunas do dataset e selecione uma variável numérica contínua que seja adequada para ser prevista em um problema de regressão.
- **Justifique** detalhadamente por que essa variável é uma boa candidata (ex.: ela tem variabilidade suficiente? Está correlacionada com outras features? Faz sentido no domínio do problema?).

- **Identificação da Variável Alvo (Target) para Classificação:**

- Selecione uma variável categórica existente ou proponha a criação de uma variável categórica a partir de uma numérica (ex.: transformar uma variável de "tempo de estudo" em "grupo de desempenho: alto/médio/baixo").
- **Justifique** a escolha e, se aplicável, explique o critério de discretização.

- **Relação entre Features e Targets:**

- Para cada um dos dois problemas (regressão e classificação), analise como as **features** (variáveis independentes) se relacionam com o **target** escolhido.
- Utilize visualizações e estatísticas para apontar quais features parecem ter maior poder preditivo (ex.: para regressão, correlação; para classificação, análise de boxplots por classe, teste de hipóteses simples como ANOVA ou qui-quadrado).

• Percepções e Recomendações para Modelagem:

- Com base em toda a análise, escreva um parágrafo conclusivo para **cada problema** (regressão e classificação) destacando:
 - * As principais features que você recomendaria para o modelo.
 - * Possíveis desafios (ex.: desbalanceamento de classes na classificação, não-linearidade na regressão).
 - * Sugestões de algoritmos que poderiam ser testados inicialmente.

Repositório de Código-Fonte

Todo o código desenvolvido para esta atividade deve ser versionado e disponibilizado em um repositório público no **GitHub** (ou plataforma similar como GitLab). O link do repositório deve ser informado na capa do relatório.

0.4 Estrutura Base Sugerida para o Repositório

Sugere-se a seguinte estrutura de diretórios e arquivos para organização do código:

Listing 1: Estrutura de diretórios sugerida para o repositório

```

1 .
2 |-- README.md                # Descrição do projeto, instruções
   de uso e link do dataset
3 |-- requirements.txt          # Dependências Python necessárias
   (ex.: pandas, numpy, matplotlib, seaborn, scikit-learn)
4 |-- data/
5 |   |-- raw/                  # Dataset original (não modificar)
6 |   |   '-- dataset.csv
7 |   '-- processed/            # Datasets após limpeza e
   pré-processamento
8 |       |-- dataset_clean.csv
9 |       |-- dataset_regression.csv
10 |       '-- dataset_classification.csv
11 |-- notebooks/
12 |   |-- 01_eda.ipynb          # Análise exploratória de dados
13 |   |-- 02_preprocessing.ipynb # Limpeza e pré-processamento
14 |   |-- 03_regression_analysis.ipynb # Percepções para regressão
15 |   '-- 04_classification_analysis.ipynb # Percepções para
   classificação
16 |-- src/
17 |   |-- __init__.py
18 |   |-- data_loader.py        # Funções para carregar dados
19 |   |-- eda.py                 # Funções para análise exploratória

```

```

20 | |-- preprocessing.py          # Funções para limpeza e
    | pré-processamento
21 | '-- visualization.py         # Funções para criação de gráficos
22 |-- reports/
23 | '-- figures/                # Gráficos gerados durante a análise
    | |-- correlation_matrix.png
24 | |-- missing_values.png
25 | |-- outliers_boxplot.png
26 |-- docs/
27 |-- relatorio_final.pdf      # Relatório técnico da atividade
28

```

0.5 Requisitos para o Repositório

- O repositório deve ser **público** para permitir a avaliação.
- O arquivo README.md deve conter:
 - Nome do aluno e matrícula.
 - Link direto para o dataset utilizado.
 - Breve descrição do projeto e dos objetivos.
 - Instruções claras de como executar o código (ex.: ordem dos notebooks, dependências necessárias).
 - Resumo dos principais resultados e percepções.
- O código deve estar **bem comentado** e organizado.
- Os notebooks devem ser executáveis na ordem apresentada, sem erros.
- Os gráficos gerados devem ser salvos na pasta **reports/figures/** e referenciados no relatório.

Exemplo de README.md:

Listing 2: Exemplo de README.md

```

1 # Análise de Dados para Machine Learning
2
3 **Aluno:** João da Silva
4 **Matrícula:** 2026123456
5 **Dataset:** [Link para o dataset](https://exemplo.com/dataset.csv)
6
7 ## Descrição
8 Este repositório contém a análise exploratória e o
   | pré-processamento de dados para a atividade da disciplina
   | DCT1401 - Inteligência Artificial. O objetivo é preparar o
   | dataset para dois problemas: regressão e classificação.
9
10 ## Estrutura
11 - 'data/raw/': Dataset original
12 - 'data/processed/': Datasets após limpeza
13 - 'notebooks/': Notebooks com as análises

```

```

14 - 'reports/figures/': Gráficos gerados
15 - 'src/': Funções auxiliares
16
17 ## Como Executar
18 1. Clone o repositório
19 2. Instale as dependências: 'pip install -r requirements.txt'
20 3. Execute os notebooks na ordem:
21     - '01_eda.ipynb'
22     - '02_preprocessing.ipynb'
23     - '03_regression_analysis.ipynb'
24     - '04_classification_analysis.ipynb'
25
26 ## Principais Resultados
27 - Para regressão, a variável alvo escolhida foi 'preco'
    (justificativa no relatório).
28 - Para classificação, a variável alvo foi 'categoria'
    (justificativa no relatório).
29 - Features mais relevantes: 'area', 'localizacao',
    'ano_construcao'.
30
31 ## Contato
32 - Email: joao.silva@ufrn.edu.br

```

Formatação e Entrega do Relatório

O relatório deve ser entregue em formato **PDF** e deve seguir a seguinte estrutura:

1. **Capa:** Contendo nome da instituição, disciplina, nome do aluno, matrícula, link do dataset utilizado e **link do repositório GitHub**.
2. **Introdução:** Breve descrição do objetivo do relatório e do dataset.
3. **Análise Exploratória:** Resultados das estatísticas, valores ausentes, outliers, correlações e visualizações, com interpretação.
4. **Limpeza e Pré-processamento:** Descrição das técnicas aplicadas e justificativas.
5. **Percepções para Regressão:** Identificação do target, análise de features e recomendações.
6. **Percepções para Classificação:** Identificação do target, análise de features e recomendações.
7. **Considerações Finais:** Resumo geral das dificuldades e aprendizados.
8. **Referência ao Repositório:** Link do repositório e breve descrição da estrutura do código.

Critérios de Avaliação:

- Completude e correção da análise exploratória (15%).

- Qualidade das justificativas para limpeza e pré-processamento (15%).
- Pertinência da escolha dos targets e qualidade das percepções para regressão (20%).
- Pertinência da escolha dos targets e qualidade das percepções para classificação (20%).
- Organização, clareza do relatório e documentação do código (15%).
- Qualidade do repositório GitHub (README, estrutura, comentários, organização) (15%).

Prazo de entrega: Conforme cronograma da disciplina.

Observações:

- Trabalhos com indícios de plágio ou cópia não serão aceitos.
- A utilização do dataset correto (conforme matrícula) é obrigatória.
- O repositório GitHub é parte integrante da avaliação e deve estar acessível.